



Plataforma Automatizada para la Optimización de Activos Financieros con Modelos Predictivos

Autores: Jhon Deivy Jerez Joya -1094860952

Juan Esteban Basto Dávila - 1093737496

RESUMEN

Este proyecto se centra en la creación de un sistema automatizado para administrar activos financieros que combina modelos predictivos y reglas de inferencia junto con teoría de autómatas. A medida que los mercados financieros se tornan más complicados y cambiantes, la importancia de una plataforma que permitirá a los inversores tomar decisiones bien fundamentadas en tiempo real. La plataforma tiene como objetivo mejorar la rentabilidad de las inversiones al prever movimientos en el mercado y reducir riesgos. Esto se logra mediante el uso de modelos de aprendizaje automático que analizan datos del pasado y tendencias en el comportamiento financiero. Además de eso se incluyen reglas de inferencia para tomar decisiones sobre la compra o venta de activos sin necesidad de intervención manual y garantizar el cumplimiento de las leyes colombianas en materia de protección de datos. Este proyecto proporciona una herramienta avanzada en el ámbito de las tecnologías financieras (Fintech), brindando la oportunidad a los inversores para incrementar la seguridad y rentabilidad de sus carteras.

Palabras clave: Gestión de Activos Financieros, Modelos Predictivos, Teoría de Autómatas, Optimización de Inversiones, Seguridad Financiera

Tabla de contenido

INTRODUCCIÓN	5
CAPÍTULO I	7
EL PROBLEMA	7
1.1 Planteamiento del Problema	7
1.2 Formulación del Problema	8
1.3 Objetivos	8
1.3.1 Objetivo General	8
1.3.2 Objetivos Específicos	8
1.4 Justificación	8
1.5	10
CAPÍTULO II	13
MARCO TEORICO	13
2.1 Estado del arte	13
2.2 Marco Referencial	13
2.3 Marco Teórico	15
2.4 Marco Conceptual	15
2.5 Marco Contextual	16
2.6 Marco Legal	17
CAPÍTULO III	18
MARCO METODOLÓGICO	18
CAPITULO IV	19
ANALISIS E INTERPRETACIÓN DE RESULTADOS	19

CAPITULO V	25
CONCLUSIONES RECOMENDACIONES	25
REFERENCIAS	27

INTRODUCCIÓN

En un entorno financiero cada vez más complejo y dinámico, la gestión eficaz de activos financieros se ha convertido en una prioridad para los inversores. Este proyecto se centra en el desarrollo de un sistema automatizado de gestión de activos financieros que utiliza modelos predictivos, reglas de inferencia y teorías de autómatas. El objetivo de este sistema es mejorar el rendimiento de la inversión y garantizar que las estrategias de gestión de activos estén alineadas de manera proactiva con los objetivos financieros de los clientes. A través de la automatización, el objetivo no es sólo reducir la intervención manual, sino también mitigar los riesgos asociados a las decisiones basadas en juicios subjetivos.

El desarrollo de este sistema tiene una relevancia significativa en el campo de la tecnología financiera (Fintech). Según un estudio el uso del *Fintech* ha estado en constante crecimiento durante los últimos años en América Latina y se espera que supere los 380 millones de usuarios para 2025, de acuerdo a las previsiones realizadas por Statista. Ello responde a la necesidad de tener soluciones financieras confiables, accesibles y fáciles de manejar. (Statista, 2024)

Tal como lo destaca (Garcia, 2024) en su análisis sobre el impacto de la inteligencia artificial en la industria financiera. Al implementar un sistema que integra modelos predictivos con teoría de autómatas, este proyecto busca no solo mejorar la eficiencia operativa, sino también proporcionar una plataforma que pueda adaptarse a cambios rápidos en el mercado, ofreciendo una ventaja competitiva significativa.

Este proyecto tiene como objetivo principal desarrollar un sistema de gestión de activos financieros que utilice modelos predictivos y teoría de autómatas para optimizar el rendimiento de las inversiones. El enfoque metodológico se basa en un análisis detallado de las limitaciones actuales de los sistemas de gestión de activos y en la implementación de soluciones basadas en tecnologías avanzadas. El impacto esperado del sistema incluye una mejora en la precisión de las asignaciones de activos,

una reducción en el riesgo de inversión, y un incremento en la satisfacción del cliente a través de la personalización de estrategias de inversión.

CAPÍTULO I

EL PROBLEMA

1.1 Planteamiento del Problema

El desarrollo de un sistema de gestión de activos es crucial en el contexto actual de volatilidad financiera. Los modelos predictivos permiten anticipar comportamientos futuros del mercado, lo que es esencial para la toma de decisiones informadas y la minimización de riesgos, es por ello que es necesario un sistema inteligente para evitar tomar decisiones perjudiciales, como lo muestra en su artículo (Alfaro, García, Gámez, & Elizondo, 2008) que esta falta de previsión y análisis adecuado llevó a decisiones de inversión que resultaron en pérdidas significativas y, finalmente, en la declaración de bancarrota. Actualmente, muchas instituciones financieras dependen de métodos tradicionales y manuales para la gestión de activos, lo que puede resultar en decisiones ineficientes y pérdidas financieras.

¿De qué manera la implementación conjunta de modelos predictivos, reglas de inferencia y teoría de autómatas en un sistema de gestión de activos financieros puede mejorar el rendimiento de las inversiones?

Idealmente, las instituciones financieras deberían contar con sistemas avanzados que integren modelos predictivos, reglas de inferencia y teoría de autómatas para gestionar sus activos. La falta de integración de tecnologías avanzadas en la gestión de activos financieros limita la capacidad de las instituciones para tomar decisiones informadas y optimizar el rendimiento de sus inversiones.

1.2 Formulación del Problema

¿Cómo desarrollar una plataforma automatizada e inteligente que permita a los usuarios acceder de manera rápida, precisa y amigable a análisis predictivos y recomendaciones sobre activos financieros, optimizando sus decisiones de inversión en un mercado en constante cambio?

1.3 Objetivos

1.3.1 Objetivo General

Desarrollar un sistema de gestión de activos financieros usando modelos predictivos, reglas de inferencia y teoría de autómatas para el rendimiento de las inversiones financieras.

1.3.2 Objetivos Específicos

- Investigar las limitaciones actuales en la gestión de activos financieros, incluyendo desafíos y oportunidades.
- Seleccionar las herramientas tecnológicas y software más adecuados para la automatización de la gestión de activos financieros.
- Desarrollar un prototipo de sistema automatizado para la gestión de activos financieros, integrando modelos predictivos, reglas de inferencia y teoría de autómatas.

1.4 Justificación

La estabilidad financiera es crucial para el bienestar de las personas y las comunidades, es por ello que el desarrollo de un sistema de gestión de activos

financieros utilizando modelos predictivos, reglas de inferencia y teoría de autómatas tiene una relevancia significativa en el contexto social actual ayudando a contribuir a una mayor seguridad económica, reduciendo el riesgo de pérdidas financieras que pueden afectar negativamente a familias y empresas.

La implementación de este proyecto representa una oportunidad para avanzar en el conocimiento y la aplicación de tecnologías emergentes en el campo de las finanzas. La integración de modelos predictivos, reglas de inferencia y teoría de autómatas no solo enriquece la literatura existente, sino que también abre nuevas líneas de investigación. Este enfoque interdisciplinario fomenta la colaboración entre diferentes áreas del conocimiento, como la informática, la economía y la matemática aplicada.

Metodológicamente, el proyecto se justifica por la necesidad de desarrollar y validar nuevas técnicas y enfoques para la gestión de activos financieros. La combinación de modelos predictivos, reglas de inferencia y teoría de autómatas ofrece un enfoque innovador que puede superar las limitaciones de los métodos tradicionales. Lo cual permitirá la creación de metodologías más precisas y eficientes, que pueden ser aplicadas en diversos contextos financieros.

Prácticamente el proyecto tiene el potencial de transformar la manera en que las instituciones financieras operan. Al utilizar modelos predictivos y reglas de inferencia, las organizaciones pueden anticipar mejor las tendencias del mercado y tomar decisiones más informadas. Esto no solo mejora el rendimiento de las inversiones, sino que también reduce el riesgo de pérdidas significativas. La teoría de autómatas, por su parte, puede automatizar procesos complejos, aumentando la eficiencia operativa y permitiendo a las instituciones centrarse en estrategias de crecimiento y desarrollo.

El proyecto se enmarca dentro de la línea de investigación de tecnologías financieras y análisis predictivo. Esta área de estudio se centra en el desarrollo y aplicación de herramientas tecnológicas para mejorar la toma de decisiones financieras. La investigación en este campo es crucial para abordar los desafíos actuales del mercado financiero, como la volatilidad y la incertidumbre. (Copilot, 2024)

1.5 Limitaciones.

Las limitaciones del desarrollo del presente proyecto son los siguientes:

1. Naturaleza Volátil del Mercado Financiero:

- Cambios Imprevistos: Los mercados financieros son altamente volátiles y pueden verse afectados por factores externos imprevistos, como crisis económicas o políticas, lo que limita la precisión de los modelos predictivos.

- Dependencia de Tendencias Pasadas: Los modelos predictivos se basan en datos históricos y pueden tener dificultades para adaptarse a nuevas condiciones de mercado o patrones no observados anteriormente.

2. Calidad y Disponibilidad de Datos:

- Datos de Fuentes Externas: La plataforma depende de datos de fuentes externas que pueden tener retrasos o interrupciones, afectando la actualización en tiempo real de la información para los usuarios.

- Ruido y Sesgos en los Datos: Los datos financieros pueden contener ruido o estar sesgados hacia ciertos activos, lo que podría afectar la precisión y confiabilidad de los modelos predictivos.

3. Limitaciones de Herramientas y Tecnologías:

- Capacidad de Procesamiento: Python y los modelos de aprendizaje automático, aunque efectivos, pueden tener limitaciones en el procesamiento de grandes volúmenes de datos en tiempo real, lo cual podría retrasar la generación de alertas o recomendaciones.

- Dependencia de APIs Externas: La plataforma depende de APIs para obtener datos actualizados sobre activos financieros, y las restricciones de acceso o cambios en estas APIs pueden limitar el funcionamiento óptimo de la plataforma.

4. Interpretabilidad de los Modelos:

- Modelos de Caja Negra: Muchos modelos de aprendizaje profundo son difíciles de interpretar, lo que limita la capacidad del sistema para justificar sus recomendaciones a los usuarios.

- **Confianza en las Recomendaciones:** La falta de transparencia en los modelos puede generar dudas en los usuarios sobre la confiabilidad de las recomendaciones de compra o venta.

5. Consideraciones Éticas y Legales:

- **Protección de Datos Personales:** La plataforma maneja información sensible de los usuarios, lo cual requiere medidas robustas de seguridad para cumplir con las normativas de protección de datos en Colombia.

- **Responsabilidad Legal:** Al recomendar decisiones de inversión, el sistema plantea cuestiones de responsabilidad en caso de pérdidas o fallos en las predicciones.

6. Validación y Generalización del Modelo:

- **Validación en Múltiples Escenarios:** Es esencial validar el modelo en diferentes escenarios de mercado para asegurar su robustez y adaptabilidad a cambios en condiciones económicas globales.

- **Desempeño en el Mercado Real:** Evaluar el sistema en un entorno de mercado real es crucial para entender su efectividad en condiciones prácticas y evitar resultados inesperados.

Mitigación de Limitaciones:

- **Actualización Continua de Modelos:** Mejorar los modelos predictivos a medida que se dispone de nuevos datos para ajustarse a las tendencias actuales del mercado.

- **Colaboración con Expertos:** Involucrar a especialistas financieros y de datos para revisar y ajustar las estrategias del sistema, mejorando así la precisión de las recomendaciones.

- **Implementación de Medidas de Seguridad:** Adoptar protocolos de seguridad y privacidad que cumplan con las leyes de protección de datos en Colombia.

- **Validación Riguroso:** Realizar pruebas exhaustivas y en distintos contextos de mercado para asegurar que los modelos sean confiables y útiles en la toma de decisiones.

En resumen, el desarrollo de esta plataforma automatizada para la gestión de activos financieros enfrenta desafíos complejos en términos de adaptación a condiciones de mercado cambiantes, integridad de los datos y cumplimiento de normativas. Al abordar estas limitaciones de manera anticipada, se pueden establecer sistemas precisos, seguros y de confianza para los usuarios.

CAPÍTULO II

MARCO TEORICO

2.1 Estado del arte

El presente capítulo de Estado del Arte explora los desarrollos recientes en la gestión automatizada de activos financieros, con énfasis en el uso de modelos predictivos, reglas de inferencia y teoría de autómatas. La evolución de las tecnologías de inteligencia artificial y aprendizaje automático ha transformado las estrategias de inversión, facilitando enfoques basados en datos y reduciendo la dependencia en juicios subjetivos. Diversos estudios, como los de Park, Cheng, y Zhu (2024), destacan el rol del aprendizaje profundo y redes neuronales en la optimización de portafolios y la precisión de las predicciones financieras. Este capítulo ofrece una revisión detallada de estas tecnologías, sus aplicaciones actuales y las oportunidades que presentan para fortalecer la precisión y eficiencia en la toma de decisiones financieras en entornos volátiles y dinámicos.

2.2 Marco Referencial

La gestión de carteras se ha convertido en un tema de gran relevancia debido a las dinámicas fluctuantes del mercado financiero. Diversos estudios han abordado este campo utilizando modelos de aprendizaje automático y, en particular, el aprendizaje por refuerzo (RL), lo cual ha permitido mejorar las estrategias de inversión.

Park, Sim y Choi (2024) proponen un enfoque innovador basado en un sistema gemelo para optimizar estrategias de cartera en un entorno dinámico. Su estudio utiliza el aprendizaje por refuerzo recurrente, optimizando la estrategia para un solo agente que administra todos los activos candidatos, logrando así decisiones más globales en

inversiones financieras. Este enfoque ha demostrado ser más efectivo que las estrategias de referencia tradicionales en los mercados de divisas y el sector estadounidense (Parque, 2024).

De manera complementaria, Cheng y Sun (2024) desarrollan un marco basado en múltiples agentes de aprendizaje por refuerzo profundo. Este enfoque permite una adaptación más eficiente en la negociación y gestión de carteras de múltiples activos. El uso de este marco, basado en el algoritmo TD3, ha mostrado mejoras significativas al mitigar la sobreestimación y el sobreajuste en las funciones de valor tradicionales (Cheng, 2024).

Otro enfoque relevante es el presentado por Park, Kim y Huh (2024), quienes incorporan el aprendizaje por refuerzo profundo en robots para el comercio algorítmico. En este estudio se analiza el rendimiento de estos robots en función de datos de acciones y tasas de interés, destacando el potencial de optimización mediante algoritmos como PPO (Kim, 2024).

Zhu, Zhong y Li (2024) exploran la predicción de precios de acciones mediante un nuevo modelo híbrido de red neuronal, el cual mejora significativamente el rendimiento de las previsiones. Este modelo combina técnicas como el algoritmo de descomposición modal empírica (CEEMDAN) y las redes convolucionales con capas LSTM, reduciendo errores de predicción y maximizando la eficacia de las decisiones financieras (Zhu, 2024).

Finalmente, el trabajo de Yadav et al. (2024) presenta una plataforma para la gestión de carteras de criptomonedas. Esta plataforma integra seguimiento en tiempo real y seguridad de datos mediante técnicas como bcrypt, ayudando a los inversores a tomar decisiones inteligentes en un entorno altamente volátil (Yadav, 2024).

Estos estudios, en su conjunto, resaltan el papel cada vez más preponderante de las tecnologías de aprendizaje automático y redes neuronales en la gestión de carteras y la toma de decisiones financieras.

2.3 Marco Teórico

El marco teórico de este proyecto se fundamenta en tres pilares: los modelos predictivos, las reglas de inferencia y la teoría de autómatas. Los modelos predictivos, sustentados en el aprendizaje automático, permiten anticipar tendencias del mercado a partir del análisis de datos históricos. Estos modelos son esenciales para prever comportamientos futuros y adaptarse a condiciones volátiles. Las reglas de inferencia, a su vez, dotan al sistema de capacidades para tomar decisiones autónomas en función de las condiciones del mercado, estableciendo relaciones causales y lógicas que orientan la gestión de activos. Finalmente, la teoría de autómatas permite la automatización y optimización de procesos complejos, facilitando la implementación de algoritmos que procesan grandes volúmenes de datos en tiempo real. Este marco teórico respalda el desarrollo del sistema de gestión de activos con una base sólida y fundamentada en la tecnología de punta.

2.4 Marco Conceptual

1. **Modelo Predictivo:** diseñados para evaluar datos históricos, descubrir patrones, observar tendencias y utilizar esa información para predecir tendencias futuras.
2. **Reglas de Inferencia:** Es una declaración en sistemas basados en reglas que consta de una cláusula "si" y una cláusula "entonces" . Estas reglas se utilizan para definir los criterios de elegibilidad del paciente y se pueden generar de forma manual o automática para realizar inferencias lógicas sobre los datos del paciente.

3. Teoría de Autómatas: Campo de estudio en computación que explora la automatización de procesos mediante estructuras finitas, aplicable aquí para procesar y analizar datos de mercado de manera sistemática.

4. Fintech (Tecnología Financiera): Uso de tecnología innovadora en el ámbito financiero, orientado a mejorar la accesibilidad, seguridad y eficiencia en la gestión de activos y transacciones.

5. Regresión lineal: La regresión lineal es una técnica de análisis de datos que predice el valor de datos desconocidos mediante el uso de otro valor de datos relacionado y conocido. Modela matemáticamente la variable desconocida o dependiente y la variable conocida o independiente como una ecuación lineal.

6. Autómata finito no determinista: (abreviado AFND) es un autómata finito que, a diferencia de los autómatas finitos deterministas (AFD), posee al menos un estado $q \in Q$, tal que para un símbolo $a \in \Sigma$ del alfabeto, existe más de una transición $\delta(q,a)$ posible. Todo AFND puede ser convertido en un AFD equivalente.

2.5 Marco Contextual

La adopción de soluciones Fintech en América Latina ha experimentado un crecimiento exponencial, y se proyecta que para 2025 el número de usuarios en la región supere los 380 millones. Este entorno, caracterizado por una necesidad creciente de automatización y personalización en la gestión de inversiones, plantea un escenario ideal para la implementación de plataformas predictivas y automatizadas. En el contexto colombiano, esta tendencia es especialmente relevante debido a la volatilidad económica y la necesidad de mejorar la accesibilidad a servicios financieros eficientes y seguros. Este proyecto se orienta a responder a estas necesidades mediante el desarrollo de un sistema automatizado que optimice el rendimiento de las inversiones,

alineándose con los desafíos y oportunidades del contexto financiero actual de Colombia y América Latina.

2.6 Marco Legal

El marco legal de este proyecto se sustenta en las regulaciones colombianas y estándares internacionales que garantizan la seguridad, transparencia y eficiencia en el uso de tecnologías financieras. En Colombia, la **Ley 1581 de 2012** establece lineamientos para la protección de datos personales, crucial para resguardar la información sensible en el sistema automatizado de gestión de activos financieros. Complementando esta ley, el **Decreto 1074 de 2015** regula las actividades Fintech en el país, fomentando la innovación tecnológica en el sector financiero bajo parámetros de responsabilidad y cumplimiento legal.

A nivel internacional, el proyecto considera la implementación de normas **ISO** específicas que aseguran la adopción de buenas prácticas en la gestión de información y riesgos. La **ISO 27001** proporciona un marco para la gestión de la seguridad de la información, ayudando a proteger los datos financieros y personales de los usuarios mediante controles específicos de seguridad. Por su parte, la **ISO 31000** establece directrices para la gestión de riesgos, permitiendo identificar, analizar y mitigar posibles amenazas en el desarrollo y operación del sistema de gestión de activos financieros. Además, la **ISO 22301** se enfoca en la continuidad del negocio, asegurando que el sistema funcione de manera estable y sin interrupciones ante situaciones imprevistas que puedan afectar su infraestructura.

Finalmente, la supervisión de la **Superintendencia Financiera de Colombia (SFC)** garantiza que el sistema se desarrolle y opere bajo las normativas locales de transparencia y seguridad en transacciones financieras, proporcionando un marco de referencia robusto que sustenta el desarrollo de este sistema innovador para la gestión automatizada de activos.

CAPÍTULO III

MARCO METODOLÓGICO

Para alcanzar los objetivos propuestos en el desarrollo del sistema de gestión de activos financieros, se seguirá un enfoque metodológico estructurado en varias fases. Estas fases incluyen la planificación, el diseño, la implementación, la validación y la evaluación del sistema. Cada fase se llevará a cabo de manera iterativa, permitiendo ajustes y mejoras continuas basadas en los resultados obtenidos. Se utilizarán técnicas de programación paralela para acelerar el procesamiento de grandes volúmenes de datos y mejorar la eficiencia del sistema, esto incluye el uso de bibliotecas y frameworks.

Los datos utilizados provendrán de diversas fuentes, bases de datos financieras, mercados de valores y registros históricos de transacciones. Estos datos serán recopilados a través de APIs y servicios de datos financieros, garantizando su actualidad y relevancia. Para asegurar la calidad y consistencia de los datos, se aplicarán diversas técnicas de preprocesamiento, como la limpieza de datos, la normalización y la imputación de valores faltantes. Estas técnicas son esenciales para preparar los datos para su análisis y modelado.

La confiabilidad del sistema se garantizará mediante pruebas exhaustivas y validaciones cruzadas utilizando datos históricos. La validez se evaluará comparando los resultados del sistema con los resultados reales del mercado, asegurando que el sistema pueda predecir con precisión las tendencias y comportamientos del mercado financiero.

CAPITULO IV

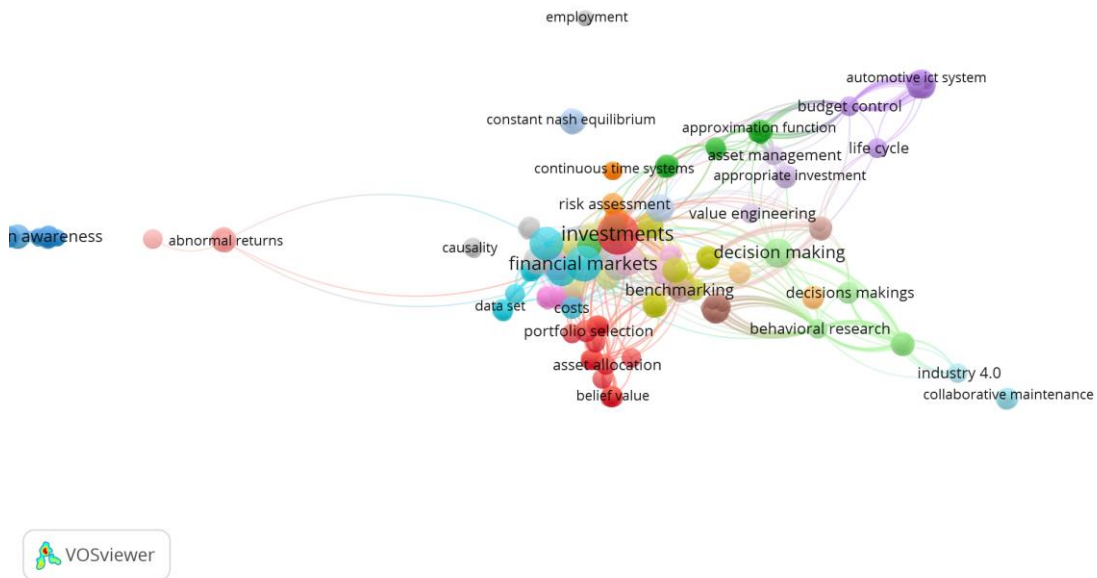
ANALISIS E INTERPRETACIÓN DE RESULTADOS

Este capítulo presenta la interpretación de los clusters generados en VOSviewer, los cuales ilustran la relación entre conceptos clave en el ámbito de los mercados financieros, la gestión de inversiones y el aprendizaje automático. A través de estos análisis se identifican patrones que revelan cómo los conceptos se interconectan para abordar los objetivos de este estudio. Las visualizaciones permiten comprender mejor los temas centrales como la optimización de carteras, la gestión de riesgos y las herramientas tecnológicas aplicadas a la toma de decisiones. Esto contribuye a la estructuración temática del área de estudio y facilita el logro de los objetivos propuestos.

Para la obtención del objetivo específico 1: Investigar las limitaciones actuales en la gestión de activos financieros, incluyendo desafíos y oportunidades:

En el análisis de clusters, términos como "financial portfolio", "portfolio optimization" y "asset allocation" forman un núcleo de conceptos interconectados que evidencian los desafíos actuales en la administración de carteras. Estos términos resaltan la necesidad de optimizar las estrategias de inversión y la selección de activos para enfrentar la volatilidad del mercado y minimizar riesgos. En la Figura 1, el cluster refleja cómo las limitaciones en la administración de portafolios afectan las decisiones de inversión, destacando áreas donde la optimización y diversificación de activos podrían mejorar el rendimiento.

Figura 1. Cluster de optimización de portafolios y gestión financiera generado en VOSviewer.

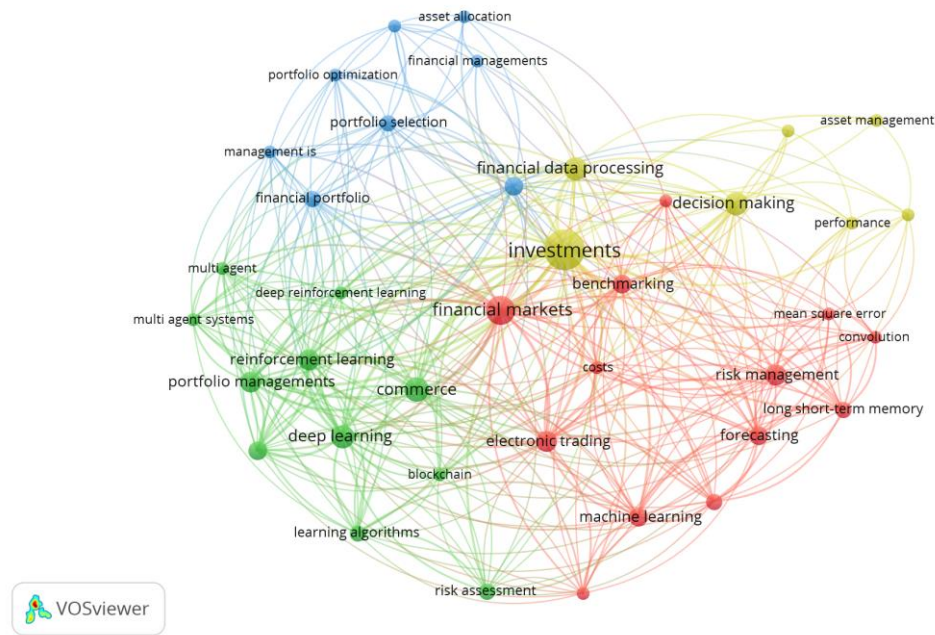


Fuente el autor

Para la obtención del objetivo específico 2: Seleccionar las herramientas tecnológicas y software más adecuados para la automatización de la gestión de activos financieros:

El análisis de clusters muestra una relación fuerte entre términos como "financial markets", "machine learning" y "risk management", lo que sugiere que la inteligencia artificial es esencial para el análisis y la gestión de riesgos financieros. La Figura 2 revela cómo el uso de herramientas tecnológicas avanzadas, como redes neuronales y algoritmos de aprendizaje profundo, puede mejorar la precisión en la predicción de tendencias y la automatización de procesos en el sector financiero. Estos hallazgos respaldan la selección de tecnologías adecuadas para responder a los desafíos del mercado y optimizar la gestión automatizada de activos financieros.

Figura 2. Cluster de relación entre inteligencia artificial, mercado financiero y gestión de riesgos.



Fuente del autor

Para la obtención del objetivo específico 3: Desarrollar un prototipo de sistema automatizado para la gestión de activos financieros, integrando modelos predictivos, reglas de inferencia y teoría de autómatas:

El script principal del sistema utiliza JavaScript para crear una visualización en tiempo real de los datos de precios de Bitcoin mediante un gráfico de líneas dinámico, con un enfoque en la actualización continua y almacenamiento de datos en el localStorage para garantizar la persistencia de información entre sesiones. Este gráfico permite monitorear cambios de precio a intervalos de un minuto, lo cual ayuda a capturar las fluctuaciones en el valor de Bitcoin y proporciona al usuario una visión clara de las tendencias de precios a corto plazo.

1. Recuperación y almacenamiento de datos: La función `updateBTCData()` realiza llamadas periódicas a la API de CoinGecko para obtener el precio actual de Bitcoin y el cambio porcentual de las últimas 24 horas. Los datos se almacenan en el `localStorage` para permitir la continuidad en la visualización sin pérdida de información entre actualizaciones.

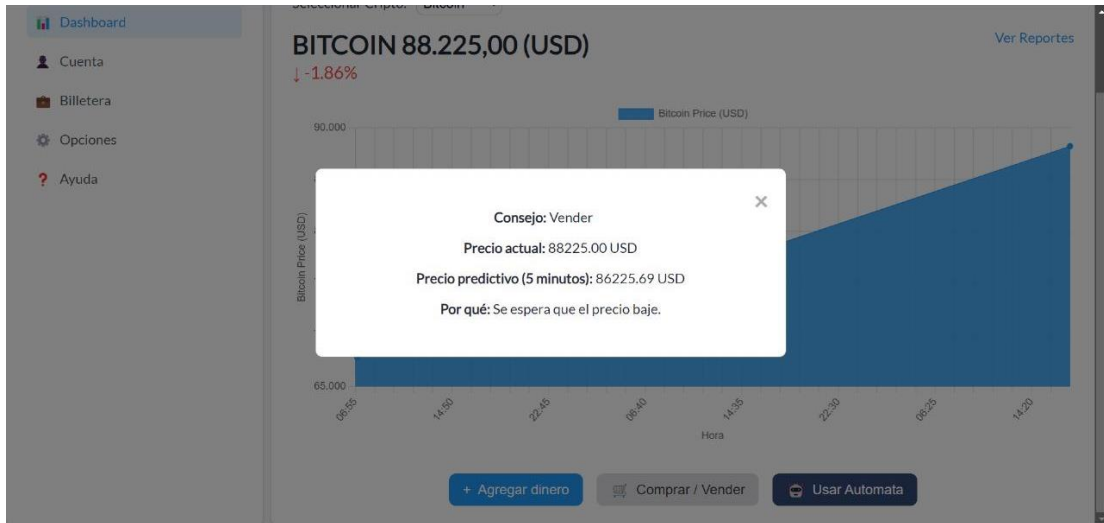
Figura 3. Visualización de los datos recopilados mediante la API de CoinGecko



Fuente del autor

2. Visualización y análisis de tendencias: El sistema utiliza la biblioteca `Chart.js` para graficar las variaciones de precio, limitando el gráfico a los últimos 240 puntos, que representan aproximadamente 4 horas de datos. Este enfoque ayuda a que el usuario vea una tendencia a corto plazo de manera fluida y comprensible, contribuyendo a la toma de decisiones informadas.

Figura 4. Representación del análisis de la tendencia y estado final de el autómata.



Fuente del autor

3. Indicador de cambio porcentual: Se muestra un cambio porcentual junto al valor actual de BTC, con una flecha visual que indica si el cambio es positivo o negativo, aportando una visión rápida del comportamiento del mercado sin necesidad de análisis exhaustivo.

Figura 5. Código del botón donde se realiza la función del autómata para determinar la variación del precio del activo.

```
document.addEventListener('DOMContentLoaded', function() {

  document.querySelector('.btn-automata').addEventListener('click', async function () {
    openModal('Analizando datos...');
    loading.style.display = 'block';

    await new Promise(resolve => setTimeout(resolve, 2000));

    const storageKey = `${currentCrypto}ChartData`;
    let storedData = JSON.parse(localStorage.getItem(storageKey));
    if (!storedData || storedData.labels.length === 0) {
      alert("No hay datos disponibles para la criptomoneda seleccionada.");
      loading.style.display = 'none';
      return;
    }

    const dates = storedData.labels.map(label => new Date(label));
    const prices = storedData.prices;

    const regressionResult = performLinearRegression(dates, prices);
    const currentPrice = prices[prices.length - 1];
    const predictedPrice = regressionResult.predictedNextPrice;
    const decision = getTradingDecision(currentPrice, predictedPrice);

    loading.style.display = 'none';

    openModal(`
      <p><strong>Consejo:</strong> ${decision}</p>
      <p><strong>Precio actual:</strong> ${currentPrice.toFixed(2)} USD</p>
      <p><strong>Precio predictivo (5 minutos):</strong> ${predictedPrice.toFixed(2)} USD</p>
      <p><strong>Por qué:</strong> ${decision === 'Comprar' ? 'Se espera que el precio suba.' : decision === 'Vender' ? 'Se espera que el precio baje.' : ''}</p>
    `);
  });
});
```

Fuente del autor

4. Resiliencia de datos: La plataforma permite una visualización adaptativa y resiliente, ya que puede manejar errores en la obtención de datos y actualiza automáticamente la información cada minuto, proporcionando un flujo constante de información al usuario.

CAPITULO V

CONCLUSIONES RECOMENDACIONES

La investigación desarrollada en este proyecto pone en evidencia las limitaciones actuales en la administración de portafolios, especialmente en lo que respecta a la optimización de estrategias y la diversificación de activos para enfrentar la volatilidad del mercado. Las herramientas tradicionales para la gestión de activos presentan desafíos en un entorno de constantes fluctuaciones, lo cual subraya la importancia de implementar modelos de optimización que maximicen el rendimiento mientras se minimizan los riesgos. Los análisis de clusters realizados sugieren que la adopción de enfoques avanzados podría transformar significativamente la administración de portafolios, permitiendo adaptarse de forma más efectiva a las variaciones del mercado.

En cuanto a la selección de herramientas tecnológicas, la investigación confirma que las redes neuronales y los algoritmos de aprendizaje profundo son fundamentales para automatizar y mejorar la precisión en el análisis de riesgos y en la toma de decisiones financieras. Estas tecnologías proporcionan la capacidad de identificar patrones complejos y responder de forma ágil a los cambios del mercado, lo cual es crítico en un entorno financiero donde las decisiones deben tomarse rápidamente. Además, la inteligencia artificial y el aprendizaje automático emergen como componentes esenciales para el desarrollo de sistemas de gestión de activos avanzados, dotando a las plataformas de una flexibilidad y rapidez necesarias en los contextos actuales de inversión.

La implementación del sistema automatizado desarrollado en este proyecto, que utiliza APIs externas y almacena datos de manera local, ha demostrado ser una solución efectiva para gestionar y visualizar datos financieros de manera continua. Esta estructura contribuye a una experiencia de usuario robusta y confiable, permitiendo una

supervisión constante del mercado. La integración de gráficos en tiempo real y el uso de indicadores visuales para reflejar cambios inmediatos brindan a los usuarios una comprensión clara de las tendencias a corto plazo, lo cual es crucial en mercados volátiles como el de las criptomonedas. En conjunto, estos elementos facilitan un entorno de decisiones informadas y respaldadas por tecnología avanzada, lo que mejora significativamente la capacidad de respuesta ante las dinámicas de los mercados financieros.

REFERENCIAS

Kumar, A., Ahmed, K., Bhayo, M., & Kalhoro, M. R. (2022). Banking performance and institutional quality: Evidence from dynamic panel data analysis. *International Journal Of Finance & Economics*, 28(4), 4717-4737. <https://doi.org/10.1002/ijfe.2673>

Lehenchuk, S., Raboshuk, A., Zhyhlei, I., Zakharov, D., & Fedoryshyna, L. (2023). Financial performance determinants of Ukrainian agricultural companies in the pre-war period. *Agricultural And Resource Economics International Scientific E-Journal*, 9(4), 102-118. <https://doi.org/10.51599/are.2023.09.04.05>

Ma, C., Zhang, J., Li, Z., & Xu, S. (2022). Multi-agent deep reinforcement learning algorithm with trend consistency regularization for portfolio management. *Neural Computing And Applications*, 35(9), 6589-6601. <https://doi.org/10.1007/s00521-022-08011-9>

Park, J., Kim, J., & Huh, J. (2024). Deep Reinforcement Learning Robots for Algorithmic Trading: Considering Stock Market Conditions and US Interest Rates. *IEEE Access*, 12, 20705-20725. <https://doi.org/10.1109/access.2024.3361035>

Pokojovy, M., Nkum, E., & Fullerton, T. M. (2024). Maximum Likelihood Estimation for Discrete Multivariate Vasicek Processes. En *Communications in computer and information science* (pp. 3-18). https://doi.org/10.1007/978-3-031-61816-1_1

Quintero-Sepúlveda, I., Gallón-Londoño, L., & Collazos, A. Z. (2024). Systemic relation between innovation capabilities, innovation strategy, and financial performance of small and medium enterprises: Impact of technology trajectory, management obstacles, and investment. *Systems Research And Behavioral Science*. <https://doi.org/10.1002/sres.3027>

Senan, N. A. M. (2024). Optimizing financial performance: The interplay between financial management and accounting information systems in Yemeni SMEs.

Asian Economic And Financial Review, 14(9), 646-659.
<https://doi.org/10.55493/5002.v14i9.5155>

Sami, L., Anjum, F., Ansari, M. S., & Iffat, B. (2024). The financial stability of the banking sector: An empirical investigation using the CAMEL rating approach. *Journal Of Governance And Regulation*, 13(2), 135-144.
<https://doi.org/10.22495/jgrv13i2art13>

Storck, F. S. D. A., & Ferreira, F. R. (2023). The effect of incentives on the performance of multimarket investment funds under public management. *Revista de Contabilidade E Organizações*, 17, e214574. <https://doi.org/10.11606/issn.1982-6486.rco.2023.214574>

colaboradores de Wikipedia. (2024, 9 agosto). *Autómata finito no determinista*. Wikipedia, la Enciclopedia Libre.
https://es.wikipedia.org/w/index.php?title=Aut%C3%B3mata_finito_no_determinista&oldid=161764908